Solución: Taller Alternativo de Teoría Aprendizaje de Maquina

Clasificación Lineal (Perceptrón) y k-Vecinos Más Cercanos (k-NN)

Por: Samuel Gómez Muñoz

10 de noviembre de 2026

Resumen

El presente documento contiene la solución detallada, demostraciones matemáticas y análisis paso a paso correspondientes al taller. Se abordan los fundamentos teóricos del clasificador lineal Perceptrón de Rosenblatt, la deducción formal de su regla de actualización mediante descenso de gradiente estocástico, el cálculo numérico de márgenes funcional y geométrico, así como el algoritmo de k-Vecinos Más Cercanos (k-NN), evaluando la distancia euclidiana, estrategias de votación mayoritaria y el análisis del compromiso entre sesgo y varianza.

---

1. Clasificación Lineal: El Algoritmo del Perceptrón

1.1. Definición del Modelo y Frontera de Decisión

Un clasificador lineal separa las clases en un espacio de características D-dimensional $\mathbb{R}^D$ mediante un hiperplano definido por el vector de pesos $w \in \mathbb{R}^D$ y el término de sesgo (o bias) $b \in \mathbb{R}$.

La función de decisión discrimina la clase de una instancia $x \in \mathbb{R}^D$ mediante:

$$f(x) = w^T x + b \tag{1}$$

La regla de clasificación asigna una etiqueta binaria $\hat{y} \in \{-1, +1\}$ según el signo de la puntuación:

$$\hat{y} = \text{signo}(w^T x + b) = \begin{cases} +1 & \text{si } w^T x + b > 0 \\ -1 & \text{si } w^T x + b \leq 0 \end{cases} \tag{2}$$

La **frontera de decisión** es el lugar geométrico del espacio donde la predicción es ambigua, correspondiente al hiperplano $w^T x + b = 0$.

Ejemplo 1.1 (Frontera de decisión en $\mathbb{R}^2$)**.** Dados los parámetros $w = \begin{bmatrix} 1 \\ 2 \end{bmatrix}$ y $b = -3$, la ecuación del hiperplano en el plano $x_1 - x_2$ es:

$$1 \cdot x_1 + 2 \cdot x_2 - 3 = 0 \tag{3}$$

Despejando la variable x_2 en función de x_1, obtenemos la ecuación explícita de la recta:

$$x_2 = -\frac{1}{2}x_1 + \frac{3}{2} \tag{4}$$

El vector normal al hiperplano es $w = [1, 2]^T$, el cual apunta en la dirección de la región donde las muestras son clasificadas como pertenecientes a la clase positiva ($+1$).

1.2. Deducción Formal de la Regla de Actualización del Perceptrón

El Perceptrón busca un hiperplano que separe perfectamente dos clases linealmente separables. Una muestra (x_i, y_i) con etiqueta $y_i \in \{-1, +1\}$ está correctamente clasificada si $y_i(w^T x_i + b) > 0$, y mal clasificada si $y_i(w^T x_i + b) \leq 0$.

Definición 1.1 (Función de Pérdida del Perceptrón)**.** Sea $\mathcal{M}(w, b)$ el conjunto de índices de las instancias mal clasificadas en el tiempo de entrenamiento. La función de pérdida del Perceptrón (Rosenblatt Loss) cuantifica el grado de error total:

$$L(w, b) = -\sum_{i \in \mathcal{M}} y_i(w^T x_i + b) \tag{5}$$

Dado que la pérdida es proporcional a la distancia funcional de los puntos mal clasificados al hiperplano, aplicamos el algoritmo de **Descenso de Gradiente Estocástico (SGD)** para minimizar $L(w, b)$ considerando una muestra individual mal clasificada $i \in \mathcal{M}$.

Calculamos las derivadas parciales de la pérdida individual $L_i(w, b) = -y_i(w^T x_i + b)$ con respecto a los parámetros:

$$\nabla_w L_i(w, b) = \frac{\partial}{\partial w}\Big(-y_i(w^T x_i + b)\Big) = -y_i x_i \tag{6}$$

$$\frac{\partial L_i(w, b)}{\partial b} = \frac{\partial}{\partial b}\Big(-y_i(w^T x_i + b)\Big) = -y_i \tag{7}$$

Dado que el descenso de gradiente actualiza en la dirección opuesta al gradiente $(-\nabla)$, con una tasa de aprendizaje $\eta > 0$:

$$w^{(t+1)} = w^{(t)} - \eta \nabla_w L_i = w^{(t)} - \eta(-y_i x_i) = w^{(t)} + \eta y_i x_i \tag{8}$$

$$b^{(t+1)} = b^{(t)} - \eta \frac{\partial L_i}{\partial b} = b^{(t)} - \eta(-y_i) = b^{(t)} + \eta y_i \tag{9}$$

Esta regla ajusta geométricamente el vector normal w rotándolo hacia la muestra positiva o alejándolo de la muestra negativa.

1.3. Cálculo Numérico de Actualización y Análisis de Margen

Considérese el siguiente escenario del taller:

- Parámetros iniciales: $w^{(0)} = \begin{bmatrix} 0 \\ 0 \end{bmatrix}$, $b^{(0)} = 0$.
- Tasa de aprendizaje: $\eta = 0{,}5$.
- Instancia de entrenamiento: $x = \begin{bmatrix} 2 \\ 1 \end{bmatrix}$ con etiqueta $y = +1$.

Paso 1: Evaluaci'on del estado inicial

Calculamos la respuesta del modelo antes de actualizar:

$$f(x) = (w^{(0)})^T x + b^{(0)} = 0 \cdot 2 + 0 \cdot 1 + 0 = 0 \tag{10}$$

El producto funcional de clasificación es:

$$y \cdot f(x) = (+1) \cdot 0 = 0 \leq 0 \tag{11}$$

Al cumplirse la condición de error $(y \cdot f(x) \leq 0)$, el Perceptrón activa la actualización de parámetros.

Paso 2: Aplicaci'on de la regla de actualizaci'on

$$w^{(1)} = w^{(0)} + \eta y x = \begin{bmatrix} 0 \\ 0 \end{bmatrix} + 0{,}5 \cdot (+1) \cdot \begin{bmatrix} 2 \\ 1 \end{bmatrix} = \begin{bmatrix} 1{,}0 \\ 0{,}5 \end{bmatrix} \tag{12}$$

$$b^{(1)} = b^{(0)} + \eta y = 0 + 0{,}5 \cdot (+1) = 0{,}5 \tag{13}$$

Paso 3: C'alculo de márgenes tras la actualizaci'on

Definición 1.2 (Margen Funcional)**.** El margen funcional γ_{func} de un punto de datos (x, y) con respecto a los parámetros (w, b) mide la confianza y corrección de la predicción:

$$\gamma_{\text{func}} = y(w^T x + b) \tag{14}$$

Sustituyendo los parámetros actualizados $w^{(1)}$ y $b^{(1)}$ para la muestra $x = [2, 1]^T$:

$$\gamma_{\text{func}} = (+1) \cdot \left(\begin{bmatrix} 1{,}0 & 0{,}5 \end{bmatrix} \begin{bmatrix} 2 \\ 1 \end{bmatrix} + 0{,}5 \right) = 1{,}0 \cdot (2{,}0 + 0{,}5 + 0{,}5) = 3{,}0 \tag{15}$$

Definición 1.3 (Margen Geométrico)**.** El margen geométrico γ_{geom} corresponde a la distancia euclidiana perpendicular real del punto x al hiperplano de decisión:

$$\gamma_{\text{geom}} = \frac{y(w^T x + b)}{\|w\|_2} = \frac{\gamma_{\text{func}}}{\|w\|_2} \tag{16}$$

Calculamos la norma euclidiana del vector de pesos actualizado $\|w^{(1)}\|_2$:

$$\|w^{(1)}\|_2 = \sqrt{(1{,}0)^2 + (0{,}5)^2} = \sqrt{1{,}0 + 0{,}25} = \sqrt{1{,}25} = \frac{\sqrt{5}}{2} \approx 1{,}11803 \tag{17}$$

Por lo tanto, el margen geométrico exacto es:

$$\gamma_{\text{geom}} = \frac{3{,}0}{\frac{\sqrt{5}}{2}} = \frac{6}{\sqrt{5}} = \frac{6\sqrt{5}}{5} \approx 2{,}68328 \text{ unidades de distancia.} \tag{18}$$

---

2. Algoritmo de k-Vecinos Más Cercanos (k-NN)

2.1. Fundamento Algorítmico

A diferencia del Perceptrón, el algoritmo de k-Vecinos Más Cercanos (k-NN) es un método **no paramétrico** e **inductivo diferido (lazy learning)**. No aprende un conjunto explicito de parámetros durante una fase de entrenamiento, sino que memoriza el conjunto de datos de entrenamiento $\mathcal{D} = \{(x_i, y_i)\}_{i=1}^N$.

Dado un punto de consulta $q \in \mathbb{R}^D$:

1. Se calcula la distancia $d(q, x_i)$ a todas las instancias $x_i \in \mathcal{D}$. La métrica estándar es la distancia euclidiana ($\mathcal{L}_2$):

$$d(q, x_i) = \|q - x_i\|_2 = \sqrt{\sum_{j=1}^{D} (q_j - x_{i,j})^2} \tag{19}$$

2. Se seleccionan las k instancias con menor distancia, denotadas por el conjunto de índices $\mathcal{N}_k(q)$.

3. Se asigna la clase mediante votación mayoritaria simple:

$$\hat{y}(q) = \arg\max_{c \in \mathcal{C}} \sum_{i \in \mathcal{N}_k(q)} \mathbb{I}(y_i = c) \tag{20}$$

donde $\mathbb{I}(\cdot)$ es la función indicadora.

2.2. Desarrollo Numérico Completo

Considere el conjunto de datos de entrenamiento bidimensional dado en la Tabla 1 y el punto de consulta $q = \begin{bmatrix} 1{,}0 \\ 1{,}0 \end{bmatrix}$.

Cuadro 1: Conjunto de datos de entrenamiento para k-NN.

Instancia (i)	**Vector** x_i	**Clase** y_i
1	$[1{,}1, 1{,}1]^T$	B
2	$[1{,}0, 0{,}0]^T$	A
3	$[0{,}0, 0{,}0]^T$	A
4	$[3{,}0, 1{,}0]^T$	B
5	$[0{,}0, 3{,}0]^T$	B

Calculamos la distancia euclidiana entre $q = [1{,}0, 1{,}0]^T$ y cada punto x_i:

$$d(q, x_1) = \sqrt{(1{,}0 - 1{,}1)^2 + (1{,}0 - 1{,}1)^2} = \sqrt{(-0{,}1)^2 + (-0{,}1)^2} = \sqrt{0{,}02} \approx 0{,}14142 \tag{21}$$

$$d(q, x_2) = \sqrt{(1{,}0 - 1{,}0)^2 + (1{,}0 - 0{,}0)^2} = \sqrt{0^2 + 1{,}0^2} = \sqrt{1{,}0} = 1{,}00000 \tag{22}$$

$$d(q, x_3) = \sqrt{(1{,}0 - 0{,}0)^2 + (1{,}0 - 0{,}0)^2} = \sqrt{1{,}0^2 + 1{,}0^2} = \sqrt{2{,}0} \approx 1{,}41421 \tag{23}$$

$$d(q, x_4) = \sqrt{(1{,}0 - 3{,}0)^2 + (1{,}0 - 1{,}0)^2} = \sqrt{(-2{,}0)^2 + 0^2} = \sqrt{4{,}0} = 2{,}00000 \tag{24}$$

$$d(q, x_5) = \sqrt{(1{,}0 - 0{,}0)^2 + (1{,}0 - 3{,}0)^2} = \sqrt{1{,}0^2 + (-2{,}0)^2} = \sqrt{5{,}0} \approx 2{,}23607 \tag{25}$$

Ordenamos los puntos de menor a mayor distancia euclidiana al punto de consulta q (Tabla 2).

Cuadro 2: Ranking de distancias al punto de consulta $q = [1{,}0, 1{,}0]^T$.

Orden	**Instancia** (x_i)	**Distancia** $d(q, x_i)$	**Valor Exacto**	**Clase** y_i
1º	$x_1 = [1{,}1, 1{,}1]^T$	0,14142	$\sqrt{0{,}02}$	**B**
2º	$x_2 = [1{,}0, 0{,}0]^T$	1,00000	1,0	**A**
3º	$x_3 = [0{,}0, 0{,}0]^T$	1,41421	$\sqrt{2}$	**A**
4º	$x_4 = [3{,}0, 1{,}0]^T$	2,00000	2,0	**B**
5º	$x_5 = [0{,}0, 3{,}0]^T$	2,23607	$\sqrt{5}$	**B**

Evaluación de Clasificación para Diferentes Valores de k:

- **Para $k = 1$:**
  - Vecino seleccionado: $\mathcal{N}_1(q) = \{x_1\}$.

- Conteo de votos: {Clase B : 1}.
- **Predicción Final: Clase B**.

- **Para $k = 3$:**
  - Vecinos seleccionados: $\mathcal{N}_3(q) = \{x_1, x_2, x_3\}$.
  - Conteo de votos: {Clase B : 1, Clase A : 2}.
  - Mayoría: Clase A ($2 > 1$).
  - **Predicción Final: Clase A**.

- **Para $k = 5$:**
  - Vecinos seleccionados: $\mathcal{N}_5(q) = \{x_1, x_2, x_3, x_4, x_5\}$.
  - Conteo de votos: {Clase B : 3, Clase A : 2}.
  - Mayoría: Clase B ($3 > 2$).
  - **Predicción Final: Clase B**.

2.3. Análisis Teórico-Práctico: Compromiso Sesgo-Varianza (Bias-Variance Tradeoff)

El hiperparámetro k controla de forma directa la complejidad del modelo en k-NN. La pérdida esperada se descompone en:

$$\mathbb{E}\left[(y - \hat{f}(x))^2\right] = \text{Sesgo}^2\left[\hat{f}(x)\right] + \text{Var}\left[\hat{f}(x)\right] + \sigma^2_{\text{ruido}} \tag{26}$$

En experimentos prácticos (como sobre el conjunto no lineal `make_moons`), observamos la siguiente dinámica:

1. **Caso $k = 1$ (Alta Varianza / Sobreajuste / Overfitting):**
   - **Exactitud en Entrenamiento:** 100 % (1,0000). Dado que $d(x_i, x_i) = 0$, cada muestra es su propio vecino.
   - **Comportamiento Geometrico:** La frontera de decisión genera polígonos de Voronoi extremadamente complejos y fracturados alrededor de cada punto.
   - **Diagnóstico: Bajo Sesgo, Alta Varianza**. Sensible a etiquetas ruidosas y outliers en el conjunto de prueba.

2. **Caso $k = 5$ (Balance Óptimo / Sweet Spot):**
   - **Exactitud en Entrenamiento y Prueba:** Balance idóneo ($\approx$ 95,7 % en Train, $\approx$ 95,6 % en Test).
   - **Comportamiento Geométrico:** Suaviza el impacto del ruido puntual manteniendo la capacidad de adaptarse a la curvatura de las "lunas".
   - **Diagnóstico: Compromiso óptimo entre Sesgo y Varianza**.

3. **Caso $k = 15$ o mayor (Alto Sesgo / Subajuste / Underfitting):**
   - **Exactitud:** Empieza a degradarse la precisión en bordes de decisión no lineales.
   - **Comportamiento Geométrico:** La frontera de decisión se vuelve demasiado suave y casi rígida. En el límite $k \to N$, el clasificador predice siempre la clase mayoritaria global independientemente del punto de consulta q.
   - **Diagnóstico: Alto Sesgo, Baja Varianza**.

3. Comparativa Sintética entre Perceptrón y k-NN

Cuadro 3: Cuadro comparativo fundamental entre el Perceptrón y k-NN.

Criterio	**Perceptrón de Rosenblatt**	**k-Vecinos Más Cercanos (k-NN)**
Tipo de Modelo	Paramétrico	No Paramétrico
Fase de Entrenamiento	Computacionalmente activa ($O(N \cdot D)$)	Nula / Memorización ($O(1)$)
Fase de Inferencia	Extremadamente rápida ($O(D)$)	Lenta / Costosa ($O(N \cdot D)$)
Supuesto Geométrico	Separabilidad Lineal	Suavidad Local (Local Smoothness)
Sensibilidad a la Escala	No requiere normalización estricta	Requiere escalado/normalización obligatorio
Tratamiento de Outliers	Sensible (modifica el hiperplano)	Modera el impacto si $k > 1$